Universidade de Pernambuco
Escola Politécnica de Pernambuco
Physicist & Research Scientist
Discente: Vinícius Nunes Leal **E-mail:** vnl@poli.br

Inferência Estatística - Lista 1

Questão 1

Sejam $X_1, X_2, \ldots, X_n$ uma amostra aleatória de

$$f_\theta(x) = \frac{1}{\theta} e^{-(x-a)/\theta}, \quad x \geq a, \quad 0 < \theta < \infty, \tag{1}$$

em que $a \in \mathbb{R}$ é conhecido.

(a) Calcule $\mathbb{E}[X]$ e $\mathrm{Var}(X)$.

(b) Encontre $\hat{\theta}$, o estimador de máxima verossimilhança (EMV) de θ. Ele é um estimador não viesado de θ? Ele é o ENVVUM de θ?

(c) Encontre a variância de $\hat{\theta}$.

Questão 2

Sejam $X_1, X_2, \ldots, X_n$ uma amostra aleatória de X, variável aleatória com distribuição Beta de parâmetros $\alpha > 0$ e $\beta > 0$, tal que a densidade de X é

$$f_\theta(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1}(1-x)^{\beta-1}, \quad 0 < x < 1, \tag{2}$$

em que $B(\alpha, \beta) = \Gamma(\alpha)\Gamma(\beta)/\Gamma(\alpha+\beta)$.

(a) Admita que $\alpha = 1$ e ache o EMV de β.

(b) O EMV de β é o seu ENVVUM? Compare as variâncias dos dois estimadores.

(c) Mostre que o EMV de β é um estimador consistente para β.

Questão 3

Sejam $X_1, X_2, \ldots, X_n$ uma amostra aleatória de X, variável aleatória com distribuição Γ, de parâmetros $\alpha > 0$ e $\beta > 0$, tal que a densidade de X é

$$f_\theta(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta}, \quad x > 0. \tag{3}$$

Admita α conhecido.

(a) Ache o EMV de β.

(b) Encontre os EMVs de $g_1(\theta) = \mathbb{E}[X]$ e de $g_2(\theta) = \text{Var}(X)$.

(c) O EMV de $\mathbb{E}[X]$ é ENVVUM?

(d) Determine $\text{LI}(\beta)$, $\text{LI}(g_1(\beta))$ e $\text{LI}(g_2(\beta))$.

(e) O EMV de β é eficiente? É consistente?

(f) Determine a distribuição limite do EMV, quando devidamente normalizado.

Observação 1.1. Na parametrização acima, β é o parâmetro de *escala*. Valem as fórmulas clássicas $\mathbb{E}[X] = \alpha\beta$ e $\text{Var}(X) = \alpha\beta^2$. Como α é conhecido, o parâmetro desconhecido é $\theta = \beta$, e as funções do item (b) são $g_1(\beta) = \alpha\beta$ e $g_2(\beta) = \alpha\beta^2$.

Universidade de Pernambuco
Escola Politécnica de Pernambuco
Physicist & Research Scientist
Discente: Vinícius Nunes Leal **E-mail:** vnl@poli.br

Resolução

Questão 1

Sejam $X_1, X_2, \ldots, X_n$ uma amostra aleatória i.i.d. com função densidade de probabilidade

$$f_\theta(x) = \begin{cases} \frac{1}{\theta} e^{-(x-a)/\theta}, & x \geq a, \\ 0, & x < a, \end{cases} \tag{4}$$

em que $a \in \mathbb{R}$ é conhecido e $\theta > 0$ é desconhecido.

(a) Calcule $\mathbb{E}[X]$ e $\mathrm{Var}(X)$

Esperança matemática

Pela definição de esperança de uma variável aleatória contínua,

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_\theta(x)\, dx. \tag{5}$$

Como $f_\theta(x) = 0$ para $x < a$, temos

$$\mathbb{E}[X] = \int_a^{\infty} x \frac{1}{\theta} e^{-(x-a)/\theta}\, dx. \tag{6}$$

Fazendo a substituição

$$u = x - a, \qquad x = u + a, \qquad dx = du, \tag{7}$$

os limites de integração passam a ser 0 e $+\infty$. Portanto,

$$\mathbb{E}[X] = \frac{1}{\theta} \int_0^{\infty} (u + a) e^{-u/\theta}\, du. \tag{8}$$

Separando a integral,

$$\mathbb{E}[X] = \frac{1}{\theta} \int_0^{\infty} u e^{-u/\theta}\, du + \frac{a}{\theta} \int_0^{\infty} e^{-u/\theta}\, du. \tag{9}$$

Primeiramente, calculamos

$$I_1 = \int_0^{\infty} u e^{-u/\theta}\, du. \tag{10}$$

Aplicando integração por partes, escolhemos

$$\begin{cases} p = u, & dp = du, \\ dq = e^{-u/\theta}\, du, & q = -\theta e^{-u/\theta} \end{cases} \tag{11}$$

Assim,

$$I_1 = \left[-\theta u e^{-u/\theta}\right]_0^\infty + \theta \int_0^\infty e^{-u/\theta}\, du. \tag{12}$$

Como

$$\lim_{u\to\infty} u e^{-u/\theta} = 0, \tag{13}$$

o termo de fronteira é nulo. Além disso,

$$\int_0^\infty e^{-u/\theta}\, du = \left[-\theta e^{-u/\theta}\right]_0^\infty \tag{14}$$

$$= \theta \tag{15}$$

Consequentemente,

$$I_1 = \theta^2 \tag{16}$$

Substituindo os resultados na expressão da esperança,

$$\mathbb{E}[X] = \frac{\theta^2}{\theta} + \frac{a\theta}{\theta} \tag{17}$$

$$= \theta + a \tag{18}$$

Portanto,

$$\boxed{\mathbb{E}[X] = a + \theta} \tag{19}$$

Variância

Utilizamos a identidade

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - \left(\mathbb{E}[X]\right)^2 \tag{20}$$

Calculando o segundo momento,

$$\mathbb{E}[X^2] = \frac{1}{\theta}\int_0^\infty (u+a)^2 e^{-u/\theta}\, du \tag{21}$$

Desenvolvendo o quadrado,

$$(u+a)^2 = u^2 + 2au + a^2 \tag{22}$$

Logo,

$$\mathbb{E}[X^2] = \frac{1}{\theta}\int_0^\infty u^2 e^{-u/\theta}\, du + \frac{2a}{\theta}\int_0^\infty u e^{-u/\theta}\, du + \frac{a^2}{\theta}\int_0^\infty e^{-u/\theta}\, du \tag{23}$$

Já sabemos que

$$\int_0^\infty ue^{-u/\theta}\,du = \theta^2 \tag{24}$$

e

$$\int_0^\infty e^{-u/\theta}\,du = \theta \tag{25}$$

Resta calcular

$$I_2 = \int_0^\infty u^2 e^{-u/\theta}\,du \tag{26}$$

Aplicando integração por partes, com

$$\begin{cases} p = u^2, & dp = 2u\,du, \\ dq = e^{-u/\theta}\,du, & q = -\theta e^{-u/\theta}, \end{cases} \tag{27}$$

obtemos

$$I_2 = \left[-\theta u^2 e^{-u/\theta}\right]_0^\infty + 2\theta \int_0^\infty ue^{-u/\theta}\,du. \tag{28}$$

O termo de fronteira é nulo. Portanto,

$$I_2 = 2\theta \cdot \theta^2 = 2\theta^3 \tag{29}$$

Substituindo na expressão do segundo momento,

$$\mathbb{E}[X^2] = \frac{2\theta^3}{\theta} + \frac{2a\theta^2}{\theta} + \frac{a^2\theta}{\theta} \tag{30}$$

$$= 2\theta^2 + 2a\theta + a^2 \tag{31}$$

Assim,

$$\mathbb{E}[X^2] = a^2 + 2a\theta + 2\theta^2 \tag{32}$$

Como $\mathbb{E}[X] = a + \theta$, segue que

$$\mathrm{Var}(X) = a^2 + 2a\theta + 2\theta^2 - (a+\theta)^2 \tag{33}$$

$$= a^2 + 2a\theta + 2\theta^2 - a^2 - 2a\theta - \theta^2 \tag{34}$$

$$= \theta^2 \tag{35}$$

Portanto,

$$\boxed{\mathrm{Var}(X) = \theta^2} \tag{36}$$

(b) Encontre o EMV de θ. Ele é não viesado? Ele é o ENVVUM?

Estimador de máxima verossimilhança

Como $X_1, \ldots, X_n$ é uma amostra aleatória i.i.d., a função de verossimilhança é

$$L(\theta; \mathbf{x}) = \prod_{i=1}^{n} f_\theta(x_i). \tag{37}$$

Substituindo a densidade,

$$L(\theta; \mathbf{x}) = \prod_{i=1}^{n} \frac{1}{\theta} e^{-(x_i - a)/\theta} \tag{38}$$

$$= \frac{1}{\theta^n} \exp\left[-\frac{1}{\theta} \sum_{i=1}^{n} (x_i - a) \right] \tag{39}$$

Definindo

$$S = \sum_{i=1}^{n} (x_i - a), \tag{40}$$

podemos escrever

$$L(\theta; \mathbf{x}) = \theta^{-n} e^{-S/\theta}, \qquad \theta > 0. \tag{41}$$

Para simplificar os cálculos, tomamos o logaritmo da função de verossimilhança:

$$\ell(\theta) = \ln L(\theta; \mathbf{x}) \tag{42}$$

$$= -n \ln \theta - \frac{S}{\theta} \tag{43}$$

Derivando em relação a θ,

$$\frac{d\ell(\theta)}{d\theta} = -\frac{n}{\theta} + \frac{S}{\theta^2} \tag{44}$$

Igualando a derivada a zero,

$$-\frac{n}{\theta} + \frac{S}{\theta^2} = 0 \tag{45}$$

Multiplicando ambos os lados por θ^2,

$$-n\theta + S = 0 \tag{46}$$

$$n\theta = S \tag{47}$$

$$\theta = \frac{S}{n} \tag{48}$$

Portanto, o estimador candidato a EMV é

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^{n} (X_i - a) = \bar{X} - a \tag{49}$$

Para verificar que o ponto crítico é um máximo, calculamos a segunda derivada:

$$\frac{d^2\ell(\theta)}{d\theta^2} = \frac{n}{\theta^2} - \frac{2S}{\theta^3} \tag{50}$$

No ponto crítico, $S = n\hat{\theta}$. Logo,

$$\left.\frac{d^2\ell(\theta)}{d\theta^2}\right|_{\theta=\hat{\theta}} = \frac{n}{\hat{\theta}^2} - \frac{2n\hat{\theta}}{\hat{\theta}^3} \tag{51}$$

$$= -\frac{n}{\hat{\theta}^2} < 0 \tag{52}$$

Como $S > 0$ com probabilidade 1, o ponto crítico corresponde ao máximo da log-verossimilhança. Portanto,

$$\boxed{\hat{\theta}_{\text{EMV}} = \bar{X} - a} \tag{53}$$

Verificação do não viés

Um estimador é não viesado quando sua esperança é igual ao parâmetro estimado. Devemos verificar se

$$\mathbb{E}[\hat{\theta}] = \theta \tag{54}$$

Como $\hat{\theta} = \bar{X} - a$, temos

$$\mathbb{E}[\hat{\theta}] = \mathbb{E}[\bar{X} - a] \tag{55}$$

$$= \mathbb{E}[\bar{X}] - a \tag{56}$$

Por definição,

$$\mathbb{E}[\bar{X}] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] \tag{57}$$

$$= \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}[X_i] \tag{58}$$

Como as observações são identicamente distribuídas e $\mathbb{E}[X_i] = a + \theta$, segue que

$$\mathbb{E}[\bar{X}] = \frac{1}{n}\sum_{i=1}^{n}(a+\theta) \tag{59}$$

$$= \frac{n(a+\theta)}{n} \tag{60}$$

$$= a + \theta \tag{61}$$

Consequentemente,

$$\mathbb{E}[\hat{\theta}] = a + \theta - a \tag{62}$$
$$= \theta \tag{63}$$

Portanto,

$$\boxed{\mathbb{E}[\hat{\theta}] = \theta} \tag{64}$$

Assim, o estimador é não viesado, pois

$$\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta = 0 \tag{65}$$

Verificação do ENVVUM

Para verificar se $\hat{\theta}$ é o estimador não viesado de variância uniformemente mínima (ENVVUM), utilizaremos o teorema de Lehmann–Scheffé. Esse teorema estabelece que um estimador não viesado que seja função de uma estatística suficiente e completa é o único ENVVUM, salvo igualdade quase certamente.

Consideremos a estatística

$$S = \sum_{i=1}^{n} (X_i - a). \tag{66}$$

Suficiência. A função de verossimilhança pode ser escrita como

$$L(\theta; \mathbf{x}) = \theta^{-n} e^{-S/\theta}. \tag{67}$$

A dependência dos dados em relação ao parâmetro θ ocorre por meio de S. Pelo teorema da fatoração de Neyman–Fisher, S é uma estatística suficiente para θ.

Completude. Como $Y_i = X_i - a$ possui distribuição exponencial com parâmetro de escala θ, a soma

$$S = \sum_{i=1}^{n} Y_i \tag{68}$$

possui distribuição gama com parâmetro de forma n e escala θ. Sua densidade é

$$f_S(s) = \frac{s^{n-1} e^{-s/\theta}}{\Gamma(n)\theta^n}, \qquad s > 0. \tag{69}$$

Para demonstrar a completude, suponha que uma função mensurável g satisfaça

$$\mathbb{E}_\theta[g(S)] = 0, \qquad \forall \theta > 0, \tag{70}$$

com as esperanças bem definidas.

Utilizando a densidade de S,

$$\int_0^\infty g(s)\frac{s^{n-1}e^{-s/\theta}}{\Gamma(n)\theta^n}\,ds = 0 \tag{71}$$

Multiplicando ambos os lados por $\Gamma(n)\theta^n$, obtemos

$$\int_0^\infty g(s)s^{n-1}e^{-s/\theta}\,ds = 0, \qquad \forall\theta > 0. \tag{72}$$

Fazendo $\lambda = 1/\theta$, temos

$$\int_0^\infty g(s)s^{n-1}e^{-\lambda s}\,ds = 0, \qquad \forall\lambda > 0. \tag{73}$$

A expressão acima é a transformada de Laplace de $g(s)s^{n-1}$. Pela unicidade da transformada de Laplace, sob as condições de integrabilidade necessárias,

$$g(s)s^{n-1} = 0 \quad \text{quase em toda parte.} \tag{74}$$

Como $s^{n-1} > 0$ para $s > 0$, concluímos que

$$g(S) = 0 \quad \text{quase certamente.} \tag{75}$$

Portanto, S é uma estatística completa.

Aplicação do teorema de Lehmann–Scheffé. O estimador

$$\hat{\theta} = \frac{S}{n} \tag{76}$$

é uma função da estatística suficiente e completa S. Além disso, já demonstramos que ele é não viesado. Pelo teorema de Lehmann–Scheffé, concluímos que

$$\boxed{\hat{\theta}_{\text{ENVVUM}} = \hat{\theta}_{\text{EMV}} = \bar{X} - a} \tag{77}$$

Assim, o EMV é não viesado e também é o ENVVUM de θ.

(c) Encontre a variância de $\hat{\theta}$

Do item anterior, temos

$$\hat{\theta} = \bar{X} - a \tag{78}$$

Como a é uma constante, subtraí-la não altera a variância. Portanto,

$$\text{Var}(\hat{\theta}) = \text{Var}(\bar{X} - a) = \text{Var}(\bar{X}) \tag{79}$$

Pela definição da média amostral,

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \tag{80}$$

Assim,

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) \tag{81}$$

Utilizando a propriedade $\text{Var}(cY) = c^2\,\text{Var}(Y)$, obtemos

$$\text{Var}(\bar{X}) = \frac{1}{n^2}\,\text{Var}\left(\sum_{i=1}^{n} X_i\right) \tag{82}$$

Como as observações são independentes, a variância da soma é igual à soma das variâncias:

$$\text{Var}(\bar{X}) = \frac{1}{n^2}\sum_{i=1}^{n}\text{Var}(X_i) \tag{83}$$

Do item (a), sabemos que

$$\text{Var}(X_i) = \theta^2 \tag{84}$$

Logo,

$$\text{Var}(\hat{\theta}) = \frac{1}{n^2}\sum_{i=1}^{n}\theta^2 \tag{85}$$

$$= \frac{n\theta^2}{n^2} \tag{86}$$

$$= \frac{\theta^2}{n} \tag{87}$$

Portanto,

$$\boxed{\text{Var}(\hat{\theta}) = \frac{\theta^2}{n}} \tag{88}$$

Observe que a variância do estimador diminui à medida que o tamanho amostral n aumenta, indicando que suas estimativas tendem a apresentar menor dispersão em torno do parâmetro verdadeiro.

Resumo dos resultados

Os resultados obtidos são:

$$\mathbb{E}[X] = a + \theta, \tag{89}$$

$$\mathrm{Var}(X) = \theta^2, \tag{90}$$

$$\hat{\theta}_{\mathrm{EMV}} = \bar{X} - a, \tag{91}$$

$$\mathbb{E}[\hat{\theta}] = \theta, \tag{92}$$

$$\hat{\theta}_{\mathrm{ENVVUM}} = \bar{X} - a, \tag{93}$$

$$\mathrm{Var}(\hat{\theta}) = \frac{\theta^2}{n}. \tag{94}$$

Concluímos que o estimador de máxima verossimilhança de θ é não viesado e constitui o ENVVUM, com variância igual a θ^2/n.

■

Questão 2

Sejam $X_1, X_2, \ldots, X_n$ uma amostra aleatória i.i.d. de uma variável aleatória X com distribuição Beta de parâmetros $\alpha > 0$ e $\beta > 0$, cuja função densidade de probabilidade é

$$f_{\alpha,\beta}(x) = \frac{1}{B(\alpha,\beta)} x^{\alpha-1}(1-x)^{\beta-1}, \qquad 0 < x < 1, \tag{95}$$

em que

$$B(\alpha,\beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}. \tag{96}$$

(a) Admita que $\alpha = 1$ e ache o EMV de β

1. Simplificação da função densidade

Como $\alpha = 1$, a função densidade de X passa a ser

$$f_{\beta}(x) = \frac{1}{B(1,\beta)} x^{1-1}(1-x)^{\beta-1}, \qquad 0 < x < 1. \tag{97}$$

Sabemos que $x^0 = 1$. Além disso, utilizando a definição da função Beta,

$$B(1,\beta) = \frac{\Gamma(1)\Gamma(\beta)}{\Gamma(1+\beta)} \tag{98}$$

Como

$$\Gamma(1) = 1 \tag{99}$$

e

$$\Gamma(1+\beta) = \beta\Gamma(\beta), \tag{100}$$

obtemos

$$B(1,\beta) = \frac{\Gamma(\beta)}{\beta\Gamma(\beta)} \tag{101}$$

$$= \frac{1}{\beta}. \tag{102}$$

Consequentemente,

$$\frac{1}{B(1,\beta)} = \beta \tag{103}$$

Portanto, a densidade simplificada é

$$\boxed{f_\beta(x) = \beta(1-x)^{\beta-1}, \qquad 0 < x < 1} \tag{104}$$

2. Construção da função de verossimilhança

Como $X_1, \ldots, X_n$ é uma amostra aleatória i.i.d., a função de verossimilhança é dada pelo produto das densidades individuais:

$$L(\beta; \mathbf{x}) = \prod_{i=1}^{n} f_\beta(x_i) \tag{105}$$

Substituindo a densidade encontrada,

$$L(\beta; \mathbf{x}) = \prod_{i=1}^{n} \beta(1-x_i)^{\beta-1} \tag{106}$$

Separando os produtos,

$$L(\beta; \mathbf{x}) = \beta^n \prod_{i=1}^{n} (1-x_i)^{\beta-1} \tag{107}$$

Utilizando a propriedade

$$\prod_{i=1}^{n} a_i^c = \left(\prod_{i=1}^{n} a_i\right)^c, \tag{108}$$

podemos escrever a verossimilhança como

$$\boxed{L(\beta; \mathbf{x}) = \beta^n \prod_{i=1}^{n} (1-x_i)^{\beta-1}} \tag{109}$$

3. Logaritmo da função de verossimilhança

Para facilitar a maximização, tomamos o logaritmo natural da função de verossimilhança:

$$\ell(\beta) = \ln L(\beta; \mathbf{x}) \tag{110}$$

Logo,

$$\ell(\beta) = \ln \left[\beta^n \prod_{i=1}^{n} (1 - x_i)^{\beta - 1} \right] \tag{111}$$

Aplicando as propriedades dos logaritmos,

$$\ell(\beta) = n \ln \beta + (\beta - 1) \sum_{i=1}^{n} \ln(1 - x_i) \tag{112}$$

Assim,

$$\boxed{\ell(\beta) = n \ln \beta + (\beta - 1) \sum_{i=1}^{n} \ln(1 - x_i)} \tag{113}$$

4. Derivação e obtenção do ponto crítico

Derivando a log-verossimilhança em relação a β, obtemos

$$\frac{d\ell(\beta)}{d\beta} = \frac{n}{\beta} + \sum_{i=1}^{n} \ln(1 - x_i) \tag{114}$$

Para encontrar o ponto crítico, igualamos a primeira derivada a zero:

$$\frac{n}{\beta} + \sum_{i=1}^{n} \ln(1 - x_i) = 0 \tag{115}$$

Isolando o termo que contém β,

$$\frac{n}{\beta} = -\sum_{i=1}^{n} \ln(1 - x_i) \tag{116}$$

Multiplicando ambos os lados por β,

$$n = -\beta \sum_{i=1}^{n} \ln(1 - x_i) \tag{117}$$

Finalmente, isolando β, obtemos

$$\hat{\beta} = -\frac{n}{\sum_{i=1}^{n} \ln(1 - x_i)} \tag{118}$$

Substituindo as observações pelas variáveis aleatórias, o estimador de máxima verossimilhança é

$$\boxed{\hat{\beta}_{\text{EMV}} = -\frac{n}{\sum_{i=1}^{n} \ln(1 - X_i)}} \tag{119}$$

Equivalentemente, utilizando a média amostral dos valores transformados,

$$\boxed{\hat{\beta}_{\text{EMV}} = \frac{1}{-\frac{1}{n}\sum_{i=1}^{n} \ln(1 - X_i)}} \tag{120}$$

5. Verificação do máximo

Para verificar que o ponto crítico corresponde a um máximo, calculamos a segunda derivada:

$$\frac{d^2\ell(\beta)}{d\beta^2} = -\frac{n}{\beta^2}. \tag{121}$$

Como $n \geq 1$ e $\beta > 0$, temos

$$\frac{d^2\ell(\beta)}{d\beta^2} < 0. \tag{122}$$

Portanto, a log-verossimilhança é estritamente côncava em relação a β. O ponto crítico encontrado corresponde ao máximo global da função de verossimilhança.

Concluímos que

$$\boxed{\hat{\beta}_{\text{EMV}} = -\frac{n}{\sum_{i=1}^{n} \ln(1 - X_i)}} \tag{123}$$

(b) O EMV de β é o seu ENVVUM? Compare as variâncias dos dois estimadores

Para responder a esta questão, precisamos verificar se o EMV é não viesado. Em seguida, encontraremos um estimador não viesado de variância uniformemente mínima (ENVVUM) e compararemos suas variâncias.

1. Transformação da variável aleatória

Definimos a variável transformada

$$Y = -\ln(1 - X) \tag{124}$$

Como $0 < X < 1$, temos $Y > 0$. Podemos obter a distribuição de Y por meio de sua função de sobrevivência:

$$P(Y > y) = P\big(-\ln(1-X) > y\big) \tag{125}$$
$$= P\big(\ln(1-X) < -y\big) \tag{126}$$
$$= P(1 - X < e^{-y}) \tag{127}$$
$$= P(X > 1 - e^{-y}) \tag{128}$$

A função de distribuição acumulada de X é

$$F_X(x) = \int_0^x \beta(1-t)^{\beta-1}\,dt \tag{129}$$
$$= 1 - (1-x)^{\beta}, \qquad 0 < x < 1 \tag{130}$$

Portanto,

$$P(X > x) = (1-x)^{\beta} \tag{131}$$

Aplicando esse resultado,

$$P(Y > y) = P(X > 1 - e^{-y}) \tag{132}$$
$$= \left[1 - (1 - e^{-y})\right]^{\beta} \tag{133}$$
$$= e^{-\beta y}, \qquad y > 0 \tag{134}$$

Essa é a função de sobrevivência de uma distribuição exponencial com taxa β. Logo,

$$\boxed{Y = -\ln(1-X) \sim \text{Exp}(\beta)} \tag{135}$$

em que β representa o parâmetro de taxa.

Assim, para

$$Y_i = -\ln(1 - X_i), \tag{136}$$

temos

$$Y_1, \ldots, Y_n \overset{\text{i.i.d.}}{\sim} \text{Exp}(\beta). \tag{137}$$

Definindo

$$S = \sum_{i=1}^{n} Y_i = -\sum_{i=1}^{n} \ln(1 - X_i), \tag{138}$$

podemos escrever o EMV como

$$\boxed{\hat{\beta}_{\text{EMV}} = \frac{n}{S}} \tag{139}$$

Como a soma de n variáveis exponenciais independentes com taxa β segue uma distribuição gama, temos

$$S \sim \text{Gama}(n, \text{taxa } \beta). \tag{140}$$

Sua densidade é

$$f_S(s) = \frac{\beta^n}{\Gamma(n)} s^{n-1} e^{-\beta s}, \qquad s > 0. \tag{141}$$

2. Verificação do não viés do EMV

Um estimador é não viesado se sua esperança for igual ao parâmetro estimado. Precisamos calcular

$$\mathbb{E}[\hat{\beta}_{\text{EMV}}] = \mathbb{E}\left[\frac{n}{S}\right] = n\mathbb{E}\left[\frac{1}{S}\right] \tag{142}$$

Utilizando a densidade de S,

$$\mathbb{E}\left[\frac{1}{S}\right] = \int_0^\infty \frac{1}{s} f_S(s)\, ds \tag{143}$$

$$= \frac{\beta^n}{\Gamma(n)} \int_0^\infty s^{n-2} e^{-\beta s}\, ds \tag{144}$$

Usamos a identidade da função gama:

$$\int_0^\infty s^{k-1} e^{-\beta s}\, ds = \frac{\Gamma(k)}{\beta^k}, \qquad k > 0. \tag{145}$$

Para $n > 1$, tomando $k = n - 1$, obtemos

$$\int_0^\infty s^{n-2} e^{-\beta s}\, ds = \frac{\Gamma(n-1)}{\beta^{n-1}} \tag{146}$$

Logo,

$$\mathbb{E}\left[\frac{1}{S}\right] = \frac{\beta^n}{\Gamma(n)} \frac{\Gamma(n-1)}{\beta^{n-1}} \tag{147}$$

$$= \beta \frac{\Gamma(n-1)}{\Gamma(n)} \tag{148}$$

Como

$$\Gamma(n) = (n-1)\Gamma(n-1), \tag{149}$$

segue que

$$\boxed{\mathbb{E}\left[\frac{1}{S}\right] = \frac{\beta}{n-1}}, \qquad n > 1 \tag{150}$$

Portanto,

$$\mathbb{E}[\hat{\beta}_{\text{EMV}}] = n\mathbb{E}\left[\frac{1}{S}\right] \tag{151}$$

$$= \frac{n\beta}{n-1} \tag{152}$$

Assim,

$$\boxed{\mathbb{E}[\hat{\beta}_{\text{EMV}}] = \frac{n}{n-1}\beta}, \qquad n > 1. \tag{153}$$

Como

$$\frac{n}{n-1}\beta \neq \beta, \tag{154}$$

concluímos que o EMV é viesado para $n > 1$.

Seu viés é

$$\begin{aligned} \text{Bias}(\hat{\beta}_{\text{EMV}}) &= \mathbb{E}[\hat{\beta}_{\text{EMV}}] - \beta && (155)\\ &= \frac{n\beta}{n-1} - \beta && (156)\\ &= \frac{\beta}{n-1} && (157) \end{aligned}$$

Portanto,

$$\boxed{\text{Bias}(\hat{\beta}_{\text{EMV}}) = \frac{\beta}{n-1}} \tag{158}$$

Como o EMV é viesado, ele não pode ser o ENVVUM, pois o ENVVUM deve ser não viesado.

3. Obtenção do estimador não viesado

Sabemos que

$$\mathbb{E}\left[\frac{1}{S}\right] = \frac{\beta}{n-1} \tag{159}$$

Multiplicando ambos os lados por $n-1$, obtemos

$$\mathbb{E}\left[\frac{n-1}{S}\right] = \beta \tag{160}$$

Logo, o estimador

$$\boxed{\tilde{\beta} = \frac{n-1}{S} = -\frac{n-1}{\sum_{i=1}^{n} \ln(1-X_i)}} \tag{161}$$

é não viesado para β, desde que $n > 1$.

4. Demonstração de que $\tilde{\beta}$ é o ENVVUM

A função de verossimilhança da amostra pode ser expressa em função de S como

$$L(\beta; \mathbf{x}) = \beta^n e^{-\beta S}. \tag{162}$$

Pelo teorema da fatoração de Neyman–Fisher, S é uma estatística suficiente para β.
Além disso, a densidade de S é

$$f_S(s) = \frac{\beta^n}{\Gamma(n)} s^{n-1} e^{-\beta s}, \qquad s > 0. \tag{163}$$

Para verificar a completude, suponha que uma função mensurável g satisfaça

$$\mathbb{E}_\beta[g(S)] = 0, \qquad \forall \beta > 0, \tag{164}$$

com as esperanças bem definidas.
Então,

$$\frac{\beta^n}{\Gamma(n)} \int_0^\infty g(s) s^{n-1} e^{-\beta s}\, ds = 0. \tag{165}$$

Como $\beta^n/\Gamma(n) > 0$, segue que

$$\int_0^\infty g(s) s^{n-1} e^{-\beta s}\, ds = 0, \qquad \forall \beta > 0. \tag{166}$$

Pela unicidade da transformada de Laplace, sob as condições de integrabilidade necessárias,

$$g(s) s^{n-1} = 0 \quad \text{quase em toda parte.} \tag{167}$$

Como $s^{n-1} > 0$ para $s > 0$, concluímos que

$$g(S) = 0 \quad \text{quase certamente.} \tag{168}$$

Portanto, S é completa e suficiente para β.
O estimador

$$\tilde{\beta} = \frac{n-1}{S} \tag{169}$$

é uma função de S e é não viesado para β. Pelo teorema de Lehmann–Scheffé, concluímos que

$$\boxed{\hat{\beta}_{\text{ENVVUM}} = \tilde{\beta} = \frac{n-1}{S}} \tag{170}$$

Equivalentemente,

$$\boxed{\hat{\beta}_{\text{ENVVUM}} = -\frac{n-1}{\sum_{i=1}^{n} \ln(1 - X_i)}} \tag{171}$$

Portanto, o EMV não é o ENVVUM, mas o estimador $\tilde{\beta}$ é o ENVVUM para $n > 1$.

5. Cálculo da variância do EMV

Para calcular a variância de

$$\hat{\beta}_{\text{EMV}} = \frac{n}{S}, \tag{172}$$

utilizamos

$$\text{Var}(\hat{\beta}_{\text{EMV}}) = \mathbb{E}[\hat{\beta}^2_{\text{EMV}}] - \left(\mathbb{E}[\hat{\beta}_{\text{EMV}}]\right)^2. \tag{173}$$

Primeiro,

$$\mathbb{E}[\hat{\beta}^2_{\text{EMV}}] = n^2 \mathbb{E}\left[\frac{1}{S^2}\right]. \tag{174}$$

Utilizando a densidade de S,

$$\mathbb{E}\left[\frac{1}{S^2}\right] = \int_0^\infty \frac{1}{s^2} f_S(s)\, ds \tag{175}$$

$$= \frac{\beta^n}{\Gamma(n)} \int_0^\infty s^{n-3} e^{-\beta s}\, ds \tag{176}$$

Para $n > 2$, aplicamos novamente a identidade da função gama:

$$\int_0^\infty s^{n-3} e^{-\beta s}\, ds = \frac{\Gamma(n-2)}{\beta^{n-2}} \tag{177}$$

Logo,

$$\mathbb{E}\left[\frac{1}{S^2}\right] = \frac{\beta^n}{\Gamma(n)} \frac{\Gamma(n-2)}{\beta^{n-2}} \tag{178}$$

$$= \beta^2 \frac{\Gamma(n-2)}{\Gamma(n)} \tag{179}$$

Como

$$\Gamma(n) = (n-1)(n-2)\Gamma(n-2), \tag{180}$$

obtemos

$$\boxed{\mathbb{E}\left[\frac{1}{S^2}\right] = \frac{\beta^2}{(n-1)(n-2)}}, \qquad n > 2. \tag{181}$$

Consequentemente,

$$\mathbb{E}[\hat{\beta}^2_{\text{EMV}}] = \frac{n^2 \beta^2}{(n-1)(n-2)} \tag{182}$$

Como

$$\mathbb{E}[\hat{\beta}_{\text{EMV}}] = \frac{n\beta}{n-1}, \tag{183}$$

segue que

$$\mathrm{Var}(\hat{\beta}_{\mathrm{EMV}}) = \frac{n^2\beta^2}{(n-1)(n-2)} - \frac{n^2\beta^2}{(n-1)^2} \tag{184}$$

$$= \frac{n^2\beta^2}{(n-1)^2}\left(\frac{n-1}{n-2} - 1\right) \tag{185}$$

$$= \frac{n^2\beta^2}{(n-1)^2}\left(\frac{1}{n-2}\right) \tag{186}$$

Portanto,

$$\boxed{\mathrm{Var}(\hat{\beta}_{\mathrm{EMV}}) = \frac{n^2\beta^2}{(n-1)^2(n-2)}}, \qquad n > 2. \tag{187}$$

6. Cálculo da variância do ENVVUM

Sabemos que

$$\tilde{\beta} = \frac{n-1}{S} \tag{188}$$

Logo,

$$\mathrm{Var}(\tilde{\beta}) = (n-1)^2\,\mathrm{Var}\left(\frac{1}{S}\right) \tag{189}$$

Utilizando a definição de variância,

$$\mathrm{Var}\left(\frac{1}{S}\right) = \mathbb{E}\left[\frac{1}{S^2}\right] - \left(\mathbb{E}\left[\frac{1}{S}\right]\right)^2 \tag{190}$$

Substituindo os resultados já encontrados,

$$\mathrm{Var}\left(\frac{1}{S}\right) = \frac{\beta^2}{(n-1)(n-2)} - \frac{\beta^2}{(n-1)^2} \tag{191}$$

Colocando em evidência β^2,

$$\mathrm{Var}\left(\frac{1}{S}\right) = \beta^2\left[\frac{1}{(n-1)(n-2)} - \frac{1}{(n-1)^2}\right] \tag{192}$$

$$= \frac{\beta^2}{(n-1)^2(n-2)} \tag{193}$$

Portanto,

$$\mathrm{Var}(\tilde{\beta}) = (n-1)^2\frac{\beta^2}{(n-1)^2(n-2)} \tag{194}$$

$$= \frac{\beta^2}{n-2} \tag{195}$$

Concluímos que

$$\boxed{\mathrm{Var}(\hat{\beta}_{\mathrm{ENVVUM}}) = \frac{\beta^2}{n-2}}, \qquad n > 2. \tag{196}$$

7. Comparação das variâncias

As variâncias dos dois estimadores são

$$\mathrm{Var}(\hat{\beta}_{\mathrm{EMV}}) = \frac{n^2\beta^2}{(n-1)^2(n-2)} \tag{197}$$

e

$$\mathrm{Var}(\hat{\beta}_{\mathrm{ENVVUM}}) = \frac{\beta^2}{n-2} \tag{198}$$

Calculando a diferença,

$$\mathrm{Var}(\hat{\beta}_{\mathrm{EMV}}) - \mathrm{Var}(\hat{\beta}_{\mathrm{ENVVUM}}) \tag{199}$$

$$= \frac{n^2\beta^2}{(n-1)^2(n-2)} - \frac{\beta^2}{n-2} \tag{200}$$

$$= \frac{\beta^2}{n-2}\left(\frac{n^2}{(n-1)^2} - 1\right) \tag{201}$$

$$= \frac{\beta^2}{n-2}\frac{n^2-(n-1)^2}{(n-1)^2} \tag{202}$$

$$= \frac{\beta^2(2n-1)}{(n-1)^2(n-2)} \tag{203}$$

Como $\beta > 0$ e $n > 2$, essa diferença é positiva. Logo,

$$\boxed{\mathrm{Var}(\hat{\beta}_{\mathrm{EMV}}) > \mathrm{Var}(\hat{\beta}_{\mathrm{ENVVUM}})}, \qquad n > 2. \tag{204}$$

A razão entre as variâncias também pode ser escrita como

$$\boxed{\frac{\mathrm{Var}(\hat{\beta}_{\mathrm{EMV}})}{\mathrm{Var}(\hat{\beta}_{\mathrm{ENVVUM}})} = \frac{n^2}{(n-1)^2} > 1} \tag{205}$$

Portanto, para $n > 2$, o ENVVUM possui variância menor do que o EMV. Essa comparação é entre as variâncias dos estimadores; como o EMV é viesado, a comparação de seus erros quadráticos médios exigiria considerar também o viés.

(c) Mostre que o EMV de β é um estimador consistente para β

Um estimador $\hat{\beta}_n$ é consistente para β se converge em probabilidade para o verdadeiro valor do parâmetro quando o tamanho amostral aumenta. Formalmente,

$$\hat{\beta}_n \xrightarrow{P} \beta \qquad \text{quando } n \to \infty. \tag{206}$$

Do item (a), sabemos que

$$\hat{\beta}_{\text{EMV}} = -\frac{n}{\sum_{i=1}^{n} \ln(1 - X_i)}. \tag{207}$$

Definindo

$$Y_i = -\ln(1 - X_i), \tag{208}$$

podemos escrever

$$\hat{\beta}_{\text{EMV}} = \frac{n}{\sum_{i=1}^{n} Y_i} = \frac{1}{\frac{1}{n}\sum_{i=1}^{n} Y_i}. \tag{209}$$

Como demonstrado no item (b),

$$Y_i \overset{\text{i.i.d.}}{\sim} \text{Exp}(\beta). \tag{210}$$

Para uma variável exponencial com taxa β, a esperança é

$$\mathbb{E}[Y_i] = \frac{1}{\beta}. \tag{211}$$

Além disso, sua variância é

$$\text{Var}(Y_i) = \frac{1}{\beta^2} < \infty. \tag{212}$$

Como as variáveis $Y_1, \ldots, Y_n$ são independentes e identicamente distribuídas, com esperança finita, podemos aplicar a Lei Forte dos Grandes Números. Assim,

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \xrightarrow{\text{q.c.}} \mathbb{E}[Y_i] = \frac{1}{\beta}, \tag{213}$$

em que $\xrightarrow{\text{q.c.}}$ representa convergência quase certa.

Portanto,

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \xrightarrow{\text{q.c.}} \frac{1}{\beta}. \tag{214}$$

Como $\beta > 0$, o limite $1/\beta$ é estritamente positivo. A função $g(y) = 1/y$ é contínua nesse ponto. Aplicando o teorema da aplicação contínua, obtemos

$$\frac{1}{\frac{1}{n}\sum_{i=1}^{n} Y_i} \xrightarrow{\text{q.c.}} \frac{1}{1/\beta}. \tag{215}$$

Simplificando,

$$\frac{n}{\sum_{i=1}^{n} Y_i} \xrightarrow{\text{q.c.}} \beta. \tag{216}$$

Como

$$\hat{\beta}_{\text{EMV}} = \frac{n}{\sum_{i=1}^{n} Y_i}, \tag{217}$$

concluímos que

$$\boxed{\hat{\beta}_{\text{EMV}} \xrightarrow{\text{q.c.}} \beta} \tag{218}$$

A convergência quase certa implica convergência em probabilidade. Portanto,

$$\boxed{\hat{\beta}_{\text{EMV}} \xrightarrow{P} \beta} \tag{219}$$

Logo, o EMV de β é um estimador consistente para β.

Resumo dos resultados

Para $\alpha = 1$, os resultados obtidos são:

$$\hat{\beta}_{\text{EMV}} = -\frac{n}{\sum_{i=1}^{n} \ln(1 - X_i)}, \tag{220}$$

$$\mathbb{E}[\hat{\beta}_{\text{EMV}}] = \frac{n}{n-1}\beta, \qquad n > 1, \tag{221}$$

$$\text{Bias}(\hat{\beta}_{\text{EMV}}) = \frac{\beta}{n-1}, \qquad n > 1, \tag{222}$$

$$\hat{\beta}_{\text{ENVVUM}} = -\frac{n-1}{\sum_{i=1}^{n} \ln(1 - X_i)}, \tag{223}$$

$$\text{Var}(\hat{\beta}_{\text{EMV}}) = \frac{n^2\beta^2}{(n-1)^2(n-2)}, \qquad n > 2, \tag{224}$$

$$\text{Var}(\hat{\beta}_{\text{ENVVUM}}) = \frac{\beta^2}{n-2}, \qquad n > 2, \tag{225}$$

$$\hat{\beta}_{\text{EMV}} \xrightarrow{P} \beta \tag{226}$$

Concluímos que o EMV é viesado para amostras finitas, não é o ENVVUM e, apesar disso, é consistente para β. O ENVVUM é dado por

$$\boxed{\hat{\beta}_{\text{ENVVUM}} = -\frac{n-1}{\sum_{i=1}^{n} \ln(1-X_i)}}, \qquad n > 1. \tag{227}$$

■

Questão 3

Seja $X_1, X_2, \ldots, X_n$ uma amostra aleatória independente e identicamente distribuída de uma distribuição Gama com parâmetro de forma $\alpha > 0$ conhecido e parâmetro de escala $\beta > 0$ desconhecido, cuja função densidade de probabilidade é

$$f_\beta(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta}, \qquad x > 0. \tag{228}$$

Sabendo que

$$E[X] = \alpha\beta, \qquad \text{Var}(X) = \alpha\beta^2, \tag{229}$$

determine:

(a) Estimador de máxima verossimilhança de β

Como $X_1, \ldots, X_n$ são independentes, a função de verossimilhança é dada pelo produto das densidades individuais:

$$L(\beta) = \prod_{i=1}^{n} f_\beta(x_i) \tag{230}$$

$$= \prod_{i=1}^{n} \frac{1}{\beta^\alpha \Gamma(\alpha)} x_i^{\alpha-1} e^{-x_i/\beta} \tag{231}$$

$$= \frac{1}{\beta^{n\alpha}\Gamma(\alpha)^n} \left(\prod_{i=1}^{n} x_i^{\alpha-1} \right) \exp\left(-\frac{1}{\beta} \sum_{i=1}^{n} x_i \right) \tag{232}$$

Tomando o logaritmo da função de verossimilhança, obtemos

$$\ell(\beta) = \ln L(\beta) \tag{233}$$

$$= -n\alpha \ln\beta - n \ln\Gamma(\alpha) + (\alpha - 1) \sum_{i=1}^{n} \ln x_i - \frac{1}{\beta} \sum_{i=1}^{n} x_i \tag{234}$$

Para determinar o EMV, derivamos em relação a β:

$$\frac{\partial \ell(\beta)}{\partial \beta} = -\frac{n\alpha}{\beta} + \frac{1}{\beta^2}\sum_{i=1}^{n} x_i \tag{235}$$

Igualando a derivada a zero, temos

$$-\frac{n\alpha}{\beta} + \frac{1}{\beta^2}\sum_{i=1}^{n} x_i = 0 \tag{236}$$

$$-n\alpha\beta + \sum_{i=1}^{n} x_i = 0 \tag{237}$$

$$n\alpha\beta = \sum_{i=1}^{n} x_i \tag{238}$$

Portanto,

$$\widehat{\beta}_{\text{EMV}} = \frac{1}{n\alpha}\sum_{i=1}^{n} X_i \tag{239}$$

Como $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$, podemos escrever

$$\boxed{\widehat{\beta}_{\text{EMV}} = \frac{\overline{X}}{\alpha}} \tag{240}$$

Para verificar que o ponto crítico corresponde a um máximo, calculamos a segunda derivada:

$$\frac{\partial^2 \ell(\beta)}{\partial \beta^2} = \frac{n\alpha}{\beta^2} - \frac{2}{\beta^3}\sum_{i=1}^{n} x_i \tag{241}$$

Substituindo $\widehat{\beta} = \frac{\sum_i x_i}{n\alpha}$, obtemos

$$\left.\frac{\partial^2 \ell(\beta)}{\partial \beta^2}\right|_{\beta=\widehat{\beta}} = \frac{n\alpha}{\widehat{\beta}^2} - \frac{2n\alpha\widehat{\beta}}{\widehat{\beta}^3} \tag{242}$$

$$= -\frac{n\alpha}{\widehat{\beta}^2} < 0 \tag{243}$$

Logo, o ponto crítico é um máximo da log-verossimilhança.

(b) EMVs de $g_1(\beta)$ e $g_2(\beta)$

O princípio da invariância dos estimadores de máxima verossimilhança estabelece que, se $\widehat{\beta}_{\text{EMV}}$ estima β, então o EMV de uma função $g(\beta)$ é

$$\widehat{g}_{\text{EMV}} = g(\widehat{\beta}_{\text{EMV}}). \tag{244}$$

Estimador de $g_1(\beta) = E[X]$

Sabemos que

$$g_1(\beta) = E[X] = \alpha\beta. \tag{245}$$

Pelo princípio da invariância,

$$\begin{aligned} \widehat{g}_1 &= \alpha\widehat{\beta}_{\text{EMV}} && (246)\\ &= \alpha\frac{\overline{X}}{\alpha} && (247)\\ &= \overline{X} && (248) \end{aligned}$$

Portanto,

$$\boxed{\widehat{g}_1 = \overline{X}} \tag{249}$$

Estimador de $g_2(\beta) = \text{Var}(X)$

Como

$$g_2(\beta) = \text{Var}(X) = \alpha\beta^2, \tag{250}$$

seu EMV é

$$\begin{aligned} \widehat{g}_2 &= \alpha\widehat{\beta}^2_{\text{EMV}} && (251)\\ &= \alpha\left(\frac{\overline{X}}{\alpha}\right)^2 && (252)\\ &= \frac{\overline{X}^2}{\alpha} && (253) \end{aligned}$$

Assim,

$$\boxed{\widehat{g}_2 = \frac{\overline{X}^2}{\alpha}} \tag{254}$$

(c) O EMV de $E[X]$ é ENVVUM?

O estimador de máxima verossimilhança de $E[X] = \alpha\beta$ é $\widehat{g}_1 = \overline{X}$. Para verificar se ele é ENVVUM, precisamos estabelecer que é não viesado e que possui variância uniformemente mínima entre os estimadores não viesados.

1. Não tendenciosidade

Como $E[X_i] = \alpha\beta$, temos

$$E[\widehat{g}_1] = E[\overline{X}] \tag{255}$$
$$= \frac{1}{n}\sum_{i=1}^{n} E[X_i] \tag{256}$$
$$= \frac{1}{n}\sum_{i=1}^{n} \alpha\beta \tag{257}$$
$$= \alpha\beta. \tag{258}$$

Logo,

$$E[\widehat{g}_1] = g_1(\beta), \tag{259}$$

e, portanto, $\overline{X}$ é um estimador não viesado de $E[X]$.

2. Suficiência e completude

Considere a estatística

$$T = \sum_{i=1}^{n} X_i. \tag{260}$$

A função de verossimilhança pode ser escrita na forma

$$L(\beta) = \frac{1}{\Gamma(\alpha)^n}\left(\prod_{i=1}^{n} x_i^{\alpha-1}\right)\beta^{-n\alpha}\exp\left(-\frac{T}{\beta}\right). \tag{261}$$

Pelo teorema da fatoração de Neyman–Fisher, T é uma estatística suficiente para β.

Além disso, como a soma de variáveis Gama independentes com o mesmo parâmetro de escala também possui distribuição Gama, temos

$$T \sim \text{Gamma}(n\alpha, \beta), \tag{262}$$

com densidade

$$f_T(t) = \frac{1}{\Gamma(n\alpha)\beta^{n\alpha}} t^{n\alpha-1} e^{-t/\beta}, \qquad t > 0. \tag{263}$$

A família Gama acima é completa quando o parâmetro de escala β varia em $(0, \infty)$. Para verificar isso, suponha que uma função mensurável h satisfaça

$$E_\beta[h(T)] = 0 \qquad \text{para todo } \beta > 0, \tag{264}$$

com as esperanças bem definidas. Então,

$$\int_0^\infty h(t) t^{n\alpha - 1} e^{-t/\beta}\, dt = 0 \qquad \text{para todo } \beta > 0. \tag{265}$$

Essa expressão é uma transformada de Laplace que se anula para todo $1/\beta > 0$. Pela unicidade da transformada de Laplace, segue que $h(T) = 0$ quase certamente. Portanto, T é completa.

3. Aplicação do teorema de Lehmann–Scheffé

Podemos escrever

$$\widehat{g}_1 = \overline{X} = \frac{T}{n}. \tag{266}$$

Assim, $\widehat{g}_1$ é uma função de uma estatística suficiente e completa, e já demonstramos que é não viesado para $g_1(\beta)$.

Pelo teorema de Lehmann–Scheffé, $\overline{X}$ é o estimador não viesado de variância uniformemente mínima.

Portanto,

$$\boxed{\widehat{g}_1 = \overline{X} \text{ é ENVVUM para } E[X] = \alpha\beta} \tag{267}$$

(d) Limites inferiores de Cramér–Rao

O limite inferior de Cramér–Rao (LICR) estabelece que, sob as condições regulares usuais, a variância de qualquer estimador não viesado de uma função diferenciável $g(\beta)$ satisfaz

$$\operatorname{Var}(\widehat{g}) \geq \frac{[g'(\beta)]^2}{I_n(\beta)}, \tag{268}$$

em que $I_n(\beta)$ é a informação de Fisher da amostra.

1. Informação de Fisher

A log-verossimilhança é

$$\ell(\beta) = -n\alpha \ln \beta - n \ln \Gamma(\alpha) + (\alpha - 1) \sum_{i=1}^{n} \ln X_i - \frac{1}{\beta} \sum_{i=1}^{n} X_i. \tag{269}$$

Sua segunda derivada é

$$\frac{\partial^2 \ell(\beta)}{\partial \beta^2} = \frac{n\alpha}{\beta^2} - \frac{2}{\beta^3}\sum_{i=1}^{n} X_i. \tag{270}$$

A informação de Fisher é definida por

$$I_n(\beta) = -E_\beta\left[\frac{\partial^2 \ell(\beta)}{\partial \beta^2}\right] \tag{271}$$

Como $E[X_i] = \alpha\beta$, segue que

$$I_n(\beta) = -\left[\frac{n\alpha}{\beta^2} - \frac{2}{\beta^3}\sum_{i=1}^{n} E[X_i]\right] \tag{272}$$

$$= -\left[\frac{n\alpha}{\beta^2} - \frac{2n\alpha\beta}{\beta^3}\right] \tag{273}$$

$$= -\left[\frac{n\alpha}{\beta^2} - \frac{2n\alpha}{\beta^2}\right] \tag{274}$$

$$= \frac{n\alpha}{\beta^2} \tag{275}$$

Portanto,

$$\boxed{I_n(\beta) = \frac{n\alpha}{\beta^2}} \tag{276}$$

2. Limite inferior para estimar β

Para $g(\beta) = \beta$, temos $g'(\beta) = 1$. Logo,

$$\text{LICR}(\beta) = \frac{[g'(\beta)]^2}{I_n(\beta)} \tag{277}$$

$$= \frac{1}{n\alpha/\beta^2} \tag{278}$$

Assim,

$$\boxed{\text{LICR}(\beta) = \frac{\beta^2}{n\alpha}} \tag{279}$$

3. Limite inferior para estimar $g_1(\beta) = \alpha\beta$

Nesse caso,

$$g_1'(\beta) = \alpha \tag{280}$$

Portanto,

$$\mathrm{LICR}(g_1) = \frac{\alpha^2}{n\alpha/\beta^2} \tag{281}$$

$$= \frac{\alpha\beta^2}{n} \tag{282}$$

Logo,

$$\boxed{\mathrm{LICR}(g_1) = \frac{\alpha\beta^2}{n}} \tag{283}$$

4. Limite inferior para estimar $g_2(\beta) = \alpha\beta^2$

Agora,

$$g_2'(\beta) = 2\alpha\beta \tag{284}$$

Consequentemente,

$$\mathrm{LICR}(g_2) = \frac{(2\alpha\beta)^2}{n\alpha/\beta^2} \tag{285}$$

$$= \frac{4\alpha^2\beta^2\beta^2}{n\alpha} \tag{286}$$

$$= \frac{4\alpha\beta^4}{n} \tag{287}$$

Portanto,

$$\boxed{\mathrm{LICR}(g_2) = \frac{4\alpha\beta^4}{n}} \tag{288}$$

(e) O EMV de β é eficiente e consistente?

1. Eficiência

O EMV de β é

$$\widehat{\beta}_{\text{EMV}} = \frac{\overline{X}}{\alpha} \tag{289}$$

Primeiramente, calculamos sua esperança:

$$E[\widehat{\beta}_{\text{EMV}}] = \frac{1}{\alpha} E[\overline{X}] \tag{290}$$

$$= \frac{1}{\alpha}\alpha\beta \tag{291}$$

$$= \beta \tag{292}$$

Logo, o estimador é não viesado.
Como as observações são independentes,

$$\text{Var}(\widehat{\beta}_{\text{EMV}}) = \text{Var}\left(\frac{\overline{X}}{\alpha}\right) \tag{293}$$

$$= \frac{1}{\alpha^2}\text{Var}(\overline{X}) \tag{294}$$

$$= \frac{1}{\alpha^2}\frac{\text{Var}(X)}{n} \tag{295}$$

$$= \frac{1}{\alpha^2}\frac{\alpha\beta^2}{n} \tag{296}$$

$$= \frac{\beta^2}{n\alpha} \tag{297}$$

Portanto,

$$\text{Var}(\widehat{\beta}_{\text{EMV}}) = \frac{\beta^2}{n\alpha} = \text{LICR}(\beta) \tag{298}$$

Como o estimador é não viesado e sua variância atinge o limite inferior de Cramér–Rao, concluímos que ele é eficiente.

$$\boxed{\widehat{\beta}_{\text{EMV}} \text{ é eficiente}} \tag{299}$$

2. Consistência

Pela lei dos grandes números, como $X_1, \ldots, X_n$ são independentes e identicamente distribuídas e possuem esperança finita,

$$\overline{X} \xrightarrow{\text{q.c.}} E[X] = \alpha\beta. \tag{300}$$

Dividindo ambos os lados por α, que é constante e positiva, obtemos

$$\widehat{\beta}_{\text{EMV}} = \frac{\overline{X}}{\alpha} \xrightarrow{\text{q.c.}} \frac{\alpha\beta}{\alpha} = \beta. \tag{301}$$

Logo, o estimador converge quase certamente para o verdadeiro valor do parâmetro. Em particular, é consistente.

A consistência também pode ser verificada pela variância:

$$\text{Var}(\widehat{\beta}_{\text{EMV}}) = \frac{\beta^2}{n\alpha} \xrightarrow[n\to\infty]{} 0, \tag{302}$$

em conjunto com a não tendenciosidade do estimador.

Portanto,

$$\boxed{\widehat{\beta}_{\text{EMV}} \text{ é consistente}} \tag{303}$$

(f) Distribuição limite do EMV devidamente normalizado

Como X_i são independentes e identicamente distribuídas, com

$$E[X_i] = \alpha\beta, \qquad \text{Var}(X_i) = \alpha\beta^2, \tag{304}$$

podemos aplicar o Teorema Central do Limite. Assim,

$$\frac{\sqrt{n}(\overline{X} - \alpha\beta)}{\sqrt{\alpha\beta^2}} \xrightarrow{d} N(0,1). \tag{305}$$

Como $\widehat{\beta}_{\text{EMV}} = \overline{X}/\alpha$, temos

$$\sqrt{n}(\widehat{\beta}_{\text{EMV}} - \beta) = \sqrt{n}\left(\frac{\overline{X}}{\alpha} - \beta\right) \tag{306}$$

$$= \frac{\sqrt{n}(\overline{X} - \alpha\beta)}{\alpha} \tag{307}$$

Consequentemente,

$$\sqrt{n}(\widehat{\beta}_{\text{EMV}} - \beta) \xrightarrow{d} N\left(0, \frac{\alpha\beta^2}{\alpha^2}\right) \tag{308}$$

$$= N\left(0, \frac{\beta^2}{\alpha}\right) \tag{309}$$

Portanto, a distribuição limite do EMV, após a normalização usual, é

$$\boxed{\sqrt{n}(\widehat{\beta}_{\text{EMV}} - \beta) \xrightarrow{d} N\left(0, \frac{\beta^2}{\alpha}\right)} \tag{310}$$

Equivalentemente, podemos escrever a forma padronizada:

$$\boxed{\frac{\sqrt{n\alpha}}{\beta}(\widehat{\beta}_{\text{EMV}} - \beta) \xrightarrow{d} N(0,1)} \tag{311}$$

Assim, para n suficientemente grande, a distribuição amostral do estimador pode ser aproximada por

$$\boxed{\widehat{\beta}_{\text{EMV}} \overset{\text{aprox.}}{\sim} N\left(\beta, \frac{\beta^2}{n\alpha}\right)} \tag{312}$$

Resumo dos resultados

$$\widehat{\beta}_{\text{EMV}} = \frac{\overline{X}}{\alpha} \tag{313}$$

$$\widehat{g}_1 = \overline{X} \tag{314}$$

$$\widehat{g}_2 = \frac{\overline{X}^2}{\alpha} \tag{315}$$

$$\text{LICR}(\beta) = \frac{\beta^2}{n\alpha} \tag{316}$$

$$\text{LICR}(g_1) = \frac{\alpha\beta^2}{n} \tag{317}$$

$$\text{LICR}(g_2) = \frac{4\alpha\beta^4}{n} \tag{318}$$

O EMV de β é não viesado, eficiente e consistente. O EMV de $E[X]$, dado por $\overline{X}$, é o ENVVUM. ■